

# Algorytmy i struktury danych 2020

## Lista 4

### Zadanie 8

Kwiecień 2020

## 1 Treść

Doktor Zseimel postanowił zaciągnąć się do pracy na platformę wiertniczą. Niestety został zakwalifikowany do kategorii osób o statusie “overqualified” i nie dostał wymarzonej pracy. Zaproponowano mu natomiast zostanie konsultantem strategicznym koncernu naftowego, który planuje budowę dużego rurociągu przebiegającego z zachodu na wschód przez pola naftowe, na których znajduje się  $n$  wież wiertniczych. Do każdej wieży ma dochodzić odnoga głównego rurociągu po najkrótszej możliwej drodze (albo na północ, albo na południe) (zakładamy, że główny rurociąg będzie modelowany przez prostą, a odchodzące od niego odnogi będą prostymi podłączonymi do głównego rurociągu pod kątem prostym). Jakiego algorytmu powinien użyć doktor dla zadanych współrzędnych  $(x_i, y_i)$   $i = 1 \dots n$  wież, aby wyznaczyć optymalne położenie głównego rurociągu (czyli takie, dla którego suma długości odnóg jest minimalna)?

Wykaż, że można takie położenie wyznaczyć w czasie liniowym.

## 2 Rozwiązanie

Do rozwiązania potrzebne będą tylko wartości drugiej współrzędnej  $y_i$ . Odpowiedzią będzie także współrzędna  $y$ , na której powinien być wybudowany rurociąg. Niech wyznaczone  $y = y_s$ , a suma odległości to  $s$ , tj.  $\sum_{i=1}^n \|y_s - y_i\|$ . Będę udowadniać, że  $y_s$  to mediana współrzędnych wejściowych, a dokładnie:

- Jeśli liczba wież  $n$  jest **parzysta**, szukany  $y_s$  będzie dowolna wartość między górną a dolną medianą.
- Jeśli liczba wież  $n$  jest **nieparzysta**, szukany  $y_s$  będzie  $y$  mediany.

Spróbujmy odtworzyć wyznaczanie  $y_s$ . Na początku zaczynamy od pierwszej wieży. W pierwszym kroku  $y_s = y_1$ , wtedy  $s = 0$ . Przy dwóch wieżach, najmniejszą sumą odległości będzie różnica między  $y_1$  a  $y_2$ , niezależnie od wybranego  $y_1 \leq y \leq y_2$  (lub  $\geq$ , jeśli  $y_2 \geq y_1$ ). Musi być spełniony jedynie warunek  $d_1 + d_2 = \|y_1 - y_2\|$ , gdzie  $d_1 = \|y_1 - y\|$  (odległość 1) i  $d_2 = \|y_2 - y\|$  (odległość 2).

Dla wszystkich przypadków parzystych: załóżmy, że początkowo  $y_s$  wybieramy na wysokości górnej mediany. Wtedy suma odległości będzie sumą odległości  $s_1 = n/2 - 1$  wież wyżej i  $s_2 = n/2$  wież niżej, łącznie z dolną medianą. Jeżeli wybralibyśmy  $y$  rurociągu wyżej od górnej mediany o wartość  $k$ , wtedy dla wszystkich  $n/2 - 1$  wież o wyższej współrzędnej  $y$  wartość zmalałaby o  $k$ , więc  $ss_1 \geq s_1 - (n/2 - 1) * k$ . ” $\geq$ ”, ponieważ,  $k$  może być na tyle duże, że odległości od wież o wyższym  $y$  niż mediana także mogą wzrosnąć. Równocześnie, dla wież poniżej rurociągu wartość  $s_2$  wzrośnie o  $k * (n/2 + 1)$ , ponieważ trzeba doliczyć odległość do górnej mediany, więc  $ss_2 = s_2 + (n/2 + 1) * k$ . Widzimy więc, że  $ss_1 + ss_2 = s_1 + s_2 + k > s_1 + s_2$ . Natomiast zmieniając  $y_s$  rurociągu niżej od górnej mediany, ale nie niżej od dolnej, odległości rurociągu od  $n/2$  wież wyżej wszystkie wzrosną o różnicę  $k$ , a odległości od  $n/2$  wież niżej wszystkie zmaleją o różnicę  $k$ .  $k * (n/2) - k * (n/2) = 0$ , więc zmiana wysokości  $y_s$  między wartościami  $y$  dwóch median, nie powoduje wzrostu sum odległości. Analogiczny dowód przeprowadzamy dla dolnej mediany.

Jeżeli liczba wież jest nieparzysta, zakładam, że szukane  $y_s$  jest na wysokości mediany wszystkich  $y$  wież.

Wtedy dla  $(n - 1)/2$  wież o wyższym  $y$  suma odległości to  $s_1$ . Jeżeli przesunęlibyśmy rurociąg w górę o  $k$ , otrzymalibyśmy  $s' = s - k(n - 1)/2 + k(n + 1)/2 = s + k > s$ .  
Do wyznaczania mediany w czasie liniowym można użyć algorytmu **Select (median of medians)**.